Big Data e Machine Learning com Hadoop e Spark

Conteúdo

CONTEÚDO PROGRAMÁTICO

- Visão geral da ciência de dados e aprendizado de máquina em escala
- Visão geral do ecossistema do Hadoop
- Instalação de um Cluster Hadoop
- Trabalhando com dados do HDFS e tabelas do Hive usando o Hue
- Visão geral do Python
- Visão geral do R
- Visão geral do Apache Spark 2
- Leitura e gravação de dados
- Inspeção da qualidade dos dados
- Limpeza e transformação de dados
- Resumindo e agrupando dados
- Combinando, dividindo e remodelando dados
- Explorando dados
- Configuração, monitoramento e solução de problemas de aplicativos Spark
- Visão geral do aprendizado de máquina no Spark MLlib
- Extraindo, transformando e selecionando recursos
- Construindo e avaliando modelos de regressão
- Construindo e avaliando modelos de classificação
- Construindo e avaliando modelos de cluster
- Validação cruzada de modelos e hiperparâmetros de ajuste
- Construção de pipelines de aprendizado de máquina
- Implantando modelos de aprendizado de máquina

MATERIAL DIDÁTICO

- Slides do treinamento em PDF
- GitHub com exercícios e códigos exemplo
- Máquinas virtuais para exercícios simulados
- Gravação das aulas disponível durante 3 meses

INTEGRAÇÃO MYSQL & HADOOP

O que é o MySQL?

- Banco de dados relacional popular e gratuito
- Geralmente monolítico por natureza
- Mas, pode ser usado para OLTP - então exportar dados para o MySQL pode ser útil
- Dados existentes podem existir no MySQL que você deseja importar para o Hadoop

Sqoop pode manipular BIGDATA

- Na verdade, inicia trabalhos do MapReduce para manipular a importação ou exportação de seus dados!

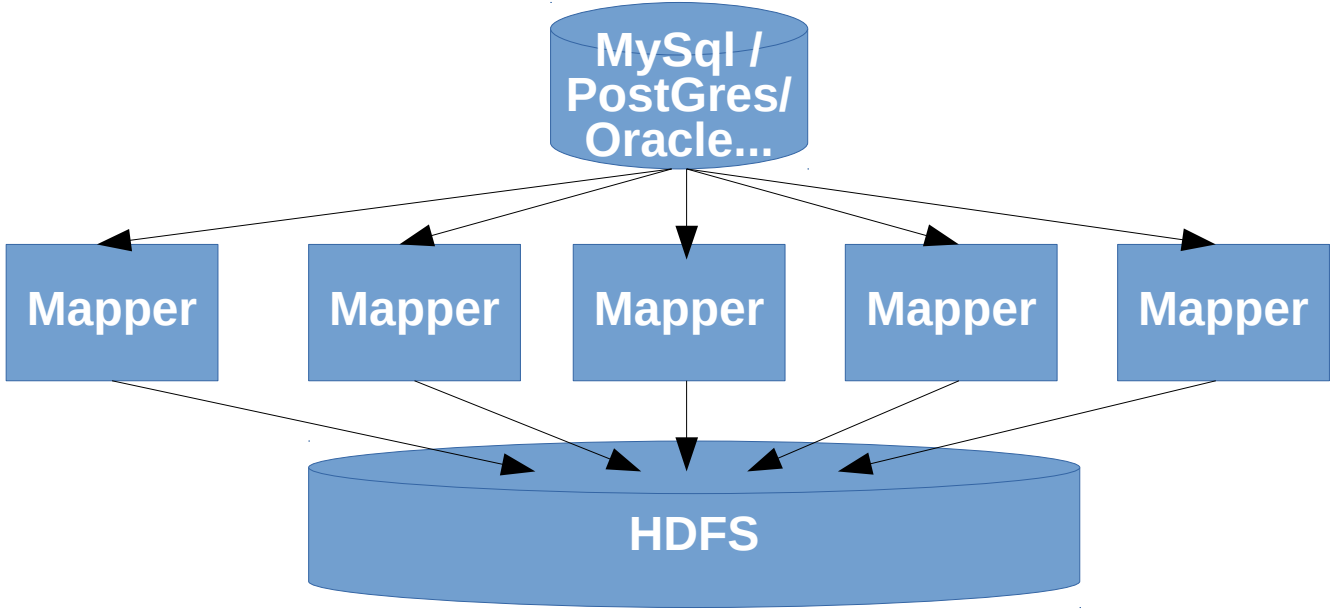

Sqoop

Importar dados do MySQL para HDFS

import sqoop --connect jdbc: mysql: // localhost / movielens –driver com.mysql.jdbc.Driver --table movies

Importar dados do MySQL diretamente no Hive

import sqoop --connect jdbc: mysql: // localhost / movielens –driver com.mysql.jdbc.Driver --table movies --hive-import

Importações incrementais

- Você pode manter seu banco de dados relacional e o Hadoop em sincronia
- --check-column e -last-value

Sqoop: Exportar dados do Hive para MySQL

- Exportação sqoop --connect jdbc: mysql: // localhost / movielens -m 1 –driver com.mysql.jdbc.Driver --table exported_movies –export-dir /apps/hive/warehouse/movies - --input-fields-terminated-by '\0001'
- A tabela de destino já deve existir no MySQL, com colunas na ordem esperada

Sqoop

Vamos praticar com o MySQL e o Sqoop

- Importe dados do MovieLens para um banco de dados MySQL
- Importe os filmes para o HDFS
- Importe os filmes para o Hive
- Exportar os filmes de volta para o MySQL

Zookeeper

O que é o ZooKeeper?

- Basicamente, ele controla as informações que devem ser sincronizadas em todo seu cluster

- Qual nó é o mestre?

- Quais tarefas são atribuídas a quais workers?

- Quais workers estão atualmente disponíveis?

- É uma ferramenta que os aplicativos podem usar para recuperar falhas parciais no cluster.

- Uma parte integrante do HBase, High-Availability (HA) MapReduce, Drill, Storm, Solr,e muito mais

Zookeeper

Modos de falha

- Master falha, precisa fazer failover para um backup
- Worker falha - seu trabalho precisa ser redistribuído
- Problemas de rede - parte do seu cluster não consegue ver o restante

Zookeeper

Operações “primitivas” em um sistema distribuído

■ Eleição mestre

- Um nó se registra como um mestre e mantém um "bloqueio" nesses dados

- Outros nós não podem se tornar mestre até que esse bloqueio seja liberado

- Apenas um nó permitido manter o bloqueio de cada vez

■ Detecção de falhas

- Os dados "efêmeros" sobre a disponibilidade de um nó desaparecem automaticamente se o nó desconecta ou falha ao atualizar após um período de tempo limite.

■ Gerenciamento de grupo

■ Metadados

- Lista de tarefas pendentes, atribuições de tarefas

Zookeeper

API do ZooKeeper:

- Criar, excluir, existir, setData, getData, getChildren

/

|

|----------/master “Master1.foobar.com:2223”

|

|----------/workers

|

|------- worker-1 “worker-2.foobar.com:2225”

|------- worker-2 “worker-5.foobar.com:2225”

Zookeeper

Notificações

- Um cliente pode se registrar para notificações em um znode

- Evita a pesquisa contínua

- Exemplo: registrar para notificação no /master - se ele parar, tente assumir como o novo mestre.

Zookeeper

Znodes persistentes e efêmeros

- Os znodes persistentes permanecem armazenados até serem excluídos explicitamente

- isto é, a atribuição de tarefas aos trabalhadores deve persistir mesmo se o mestre travar

- Os znodes efêmeros desaparecem se o cliente que o criou falhar ou perder conexão ao ZooKeeper

- ou seja, se o mestre travar, ele deve liberar seu bloqueio no znode que indica qual nó é o mestre!

Zookeeper

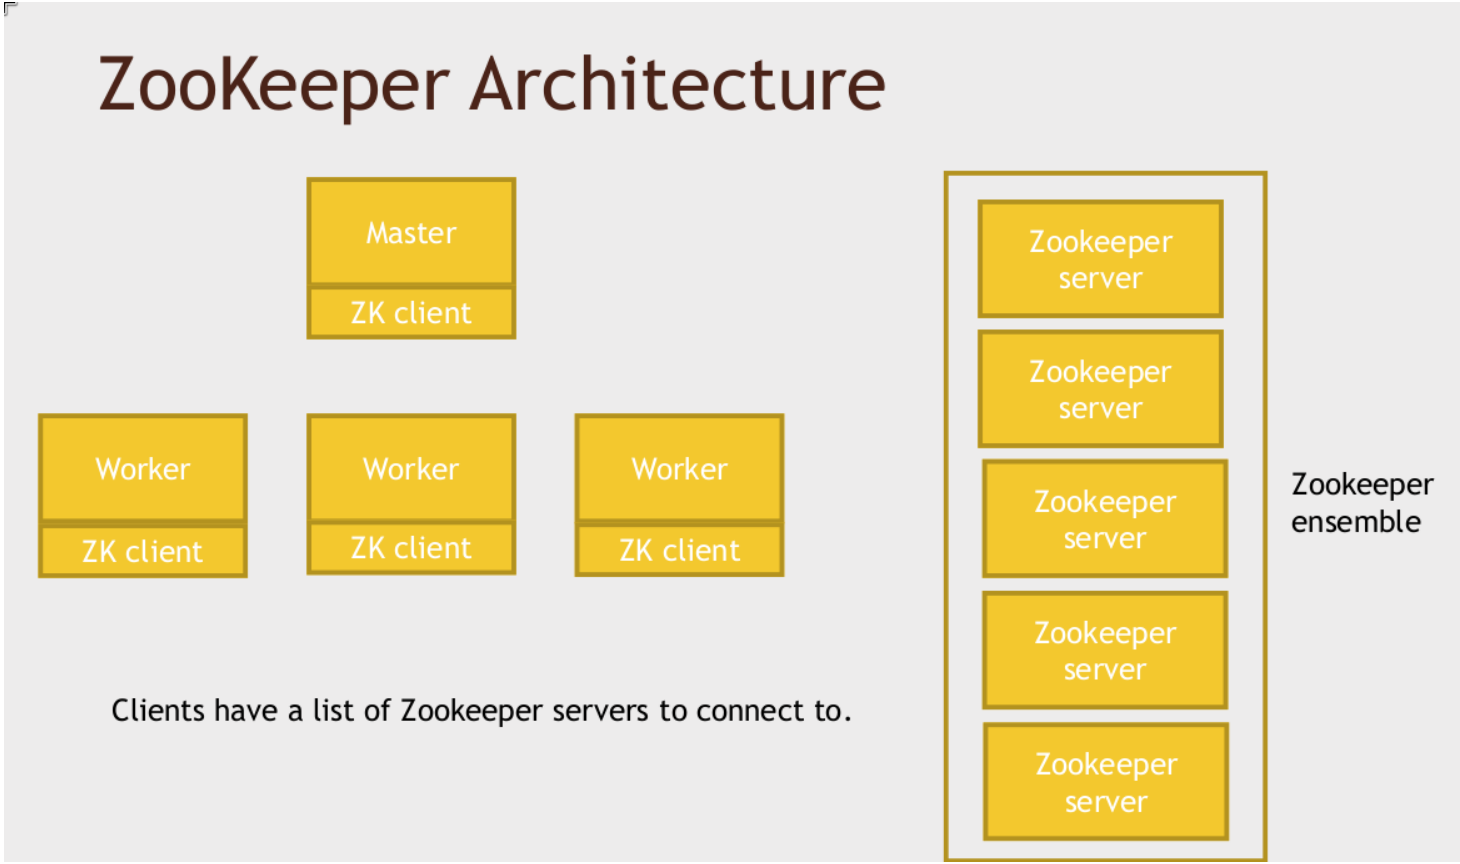
ZooKeeper Architecture
Master
ZK client
Worker
ZK client
Worker
ZK client
Worker
ZK client
Clients have a list of Zookeeper servers to connect to.
Zookeeper server
Zookeeper server
Zookeeper server
Zookeeper server
Zookeeper server
Zookeeper ensemble

Storm

Processamento de fluxo em tempo real

O que é o Apache Storm?

■ Framework para processar fluxos contínuos de dados em um cluster

- Pode rodar em cima do YARN (como Spark)

■ Funciona em eventos individuais, não em micro lotes (como o Spark Streaming)

- Se você precisa de latência de sub-segundo, Storm é a opção

Storm

Terminologia do Storm

- Um ***stream*** consiste em tuplas que fluem através de…
- ***Spouts*** que são fontes de dados de fluxo (Kafka, Twitter, etc.)
- ***Bolts*** que processam dados de fluxo conforme são recebidos

- Transformar, agregar, gravar em bancos de dados / HDFS

- Uma ***topology*** é um gráfico de ***Spouts*** e ***Bolts*** que processam seu fluxo

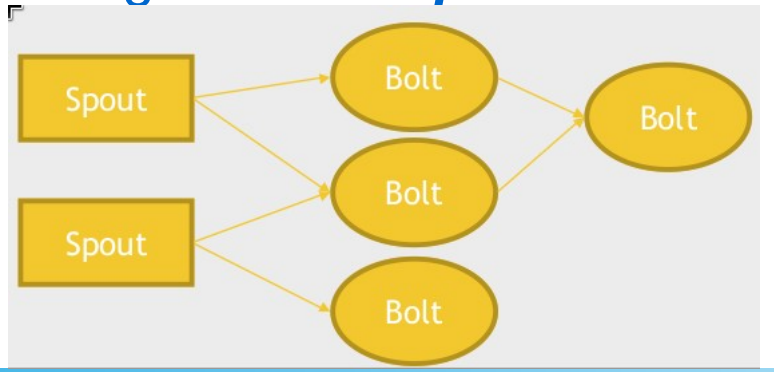

Storm

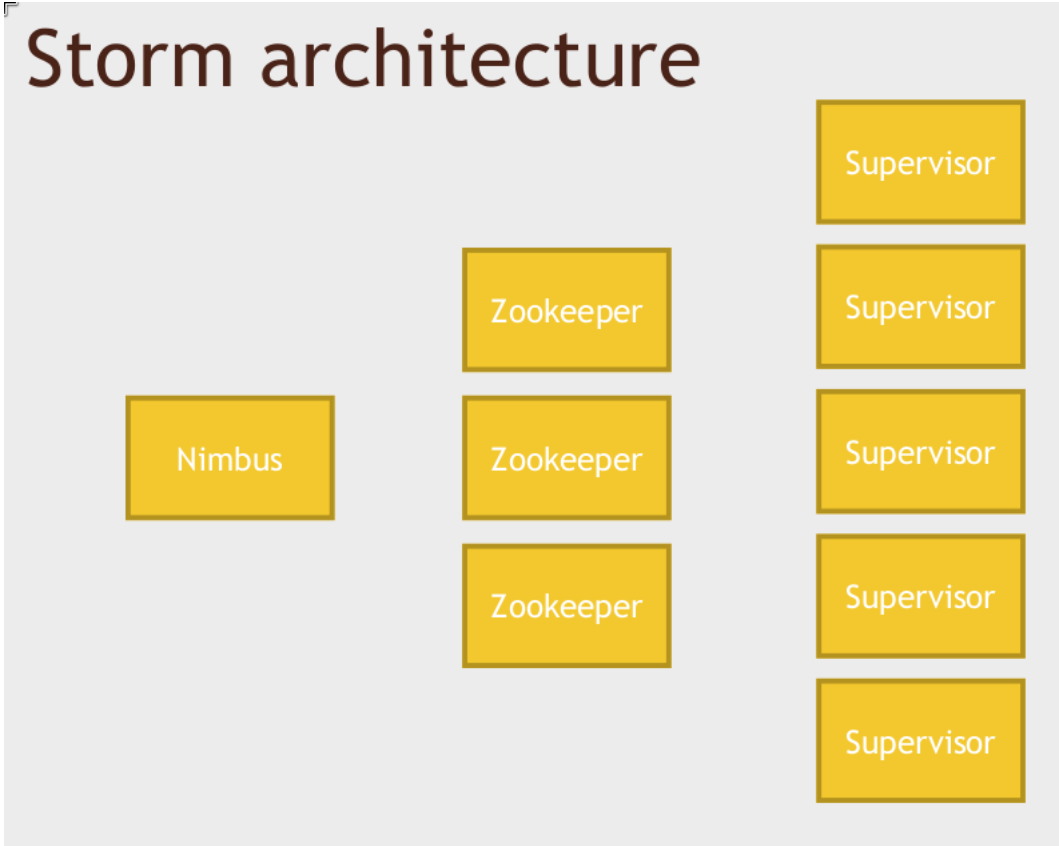
Storm architecture
Supervisor
Zookeeper
Supervisor
Nimbus
Zookeeper
Supervisor
Zookeeper
Supervisor
Supervisor

Storm

Desenvolvendo aplicativos Storm

■ Geralmente feito com Java

- Embora os bolts possam ser direcionados através de scripts em outros idiomas

Núcleo do Storm

- A API de nível inferior para o Storm

- Semântica "pelo menos uma vez"

■ Trident

- API de nível superior para tempestade

- semântica “Exactly once”

■ O Storm executa seus aplicativos “para sempre” depois de enviado - até você explicitamente pare

Storm

Storm vs. Spark Streaming

- Apesar do Spark ter mais ferramentas...

se você precisar de processamento em tempo real (sub-segundo) de eventos, em, Storm é sua escolha

- Kafka + Storm é uma combinação bastante popular

Flume

O que é o Flume?

- Outra maneira de transmitir dados em seu cluster
- Feito desde o início com o Hadoop em mente

- Dissipadores embutidos para HDFS e Hbase

- Originalmente feito para manipular a agregação de logs

Anatomia de um Flume Agent and Flow

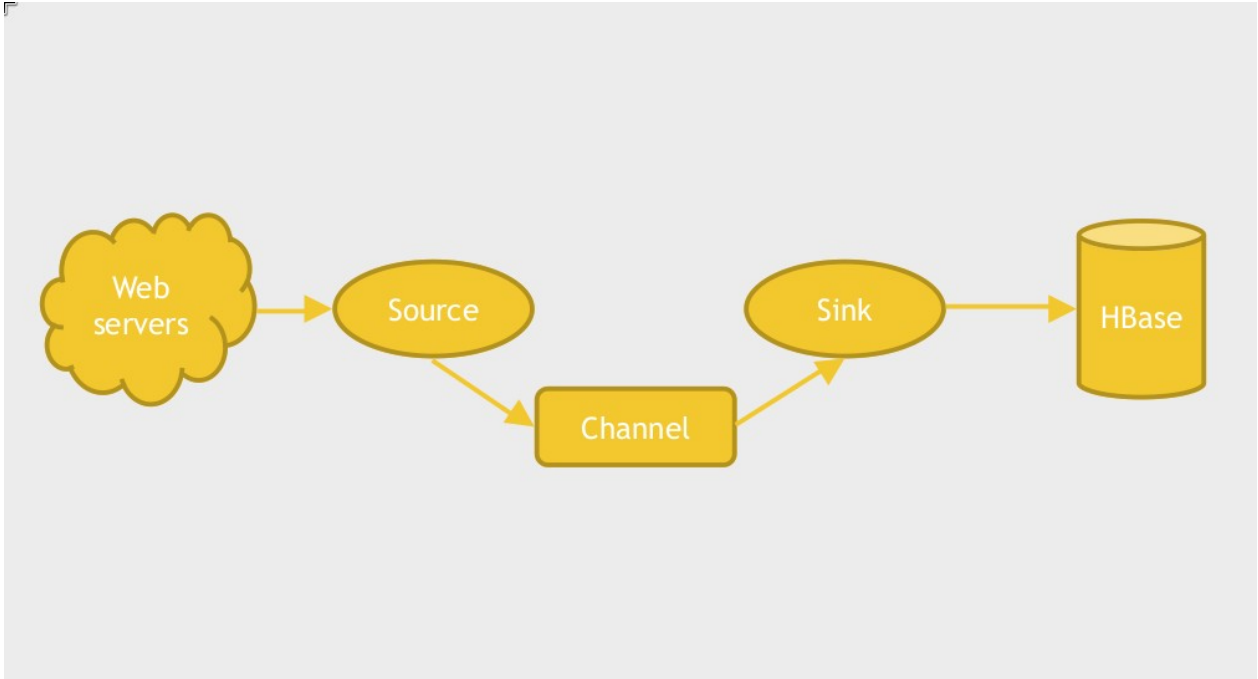

Flume

Componentes de um agente

- Fonte

- De onde vêm os dados

- Opcionalmente, pode ter Seletores de Canal e Interceptores

- Canal

- Como os dados são transferidos (via memória ou arquivos)

- Pia (Sink)

- Onde os dados estão indo

- Pode ser organizado em grupos de pia

- Uma pia pode se conectar a apenas um canal

Flume

Componentes de um agente

■ Fonte

- De onde vêm os dados
- Opcionalmente, pode ter Seletores de Canal e Interceptores

■ Canal

- Como os dados são transferidos (via memória ou arquivos)

■ Pia (Sink)

- Onde os dados estão indo
- Pode ser organizado em grupos de pia
- Uma pia pode se conectar a apenas um canal

O canal é notificado para excluir uma mensagem quando o coletor a processa.

Flume

Usando o Avro, os agentes podem se conectar outros agentes também

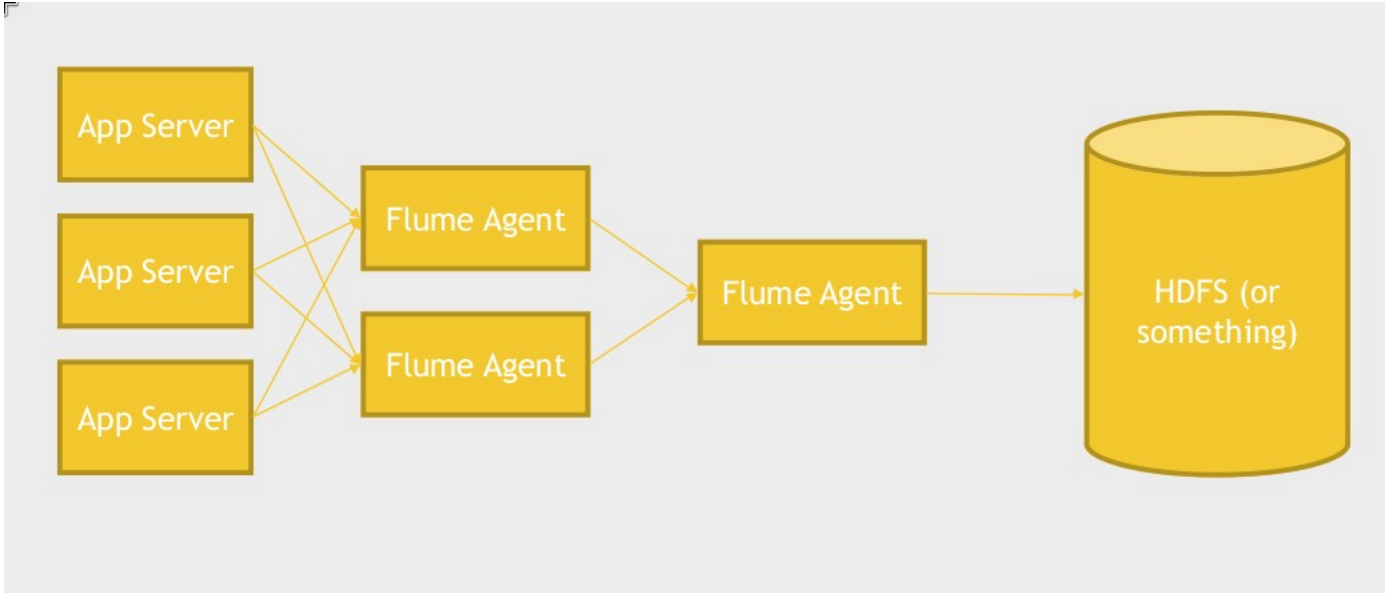

Flume

Tipos de Sink Built-in

- HDFS
- Hive
- HBase
- Avro
- Thrift
- Elasticsearch
- Kafka
- Personalizado
- E mais!

STREAMING COM KAFKA

Publicar / Assinar Mensagens com Kafka

O que é streaming?

■ Conversamos sobre o processamento de big data histórico e existente

- residente no HDFS

- residente em um banco de dados

■ Mas como os novos dados chegam ao seu cluster? Especialmente se for "Big Data"?

- Novas entradas de log dos seus servidores da web

- Novos dados do sensor do seu sistema IoT

- Novas negociações de ações

■ Streaming permite publicar esses dados, em tempo real, em seu cluster.

- E você pode até processá-lo em tempo real quando ele chegar!

Kafka

Dois problemas

- Como obter dados de várias fontes diferentes fluindo para o cluster
- Processaestes dados quando chegarem
- Primeiro, vamos nos concentrar no primeiro problema

Kafka

- Kafka é um sistema de publicação / assinatura de mensagensde propósito geral
- Os servidores Kafka armazenam todas as mensagens recebidas dos ***publishers*** por um período de tempo, e publica-os em um fluxo de dados (***stream***) chamado ***topic***.
- Os ***consumers*** se inscrevem em um ou mais ***topics*** e recebem dados a medida que são publicados
- Um stream / topic pode ter muitos ***consumers*** diferentes, todos com suas próprios

posição no fluxo mantido

- Não é apenas para o Hadoop

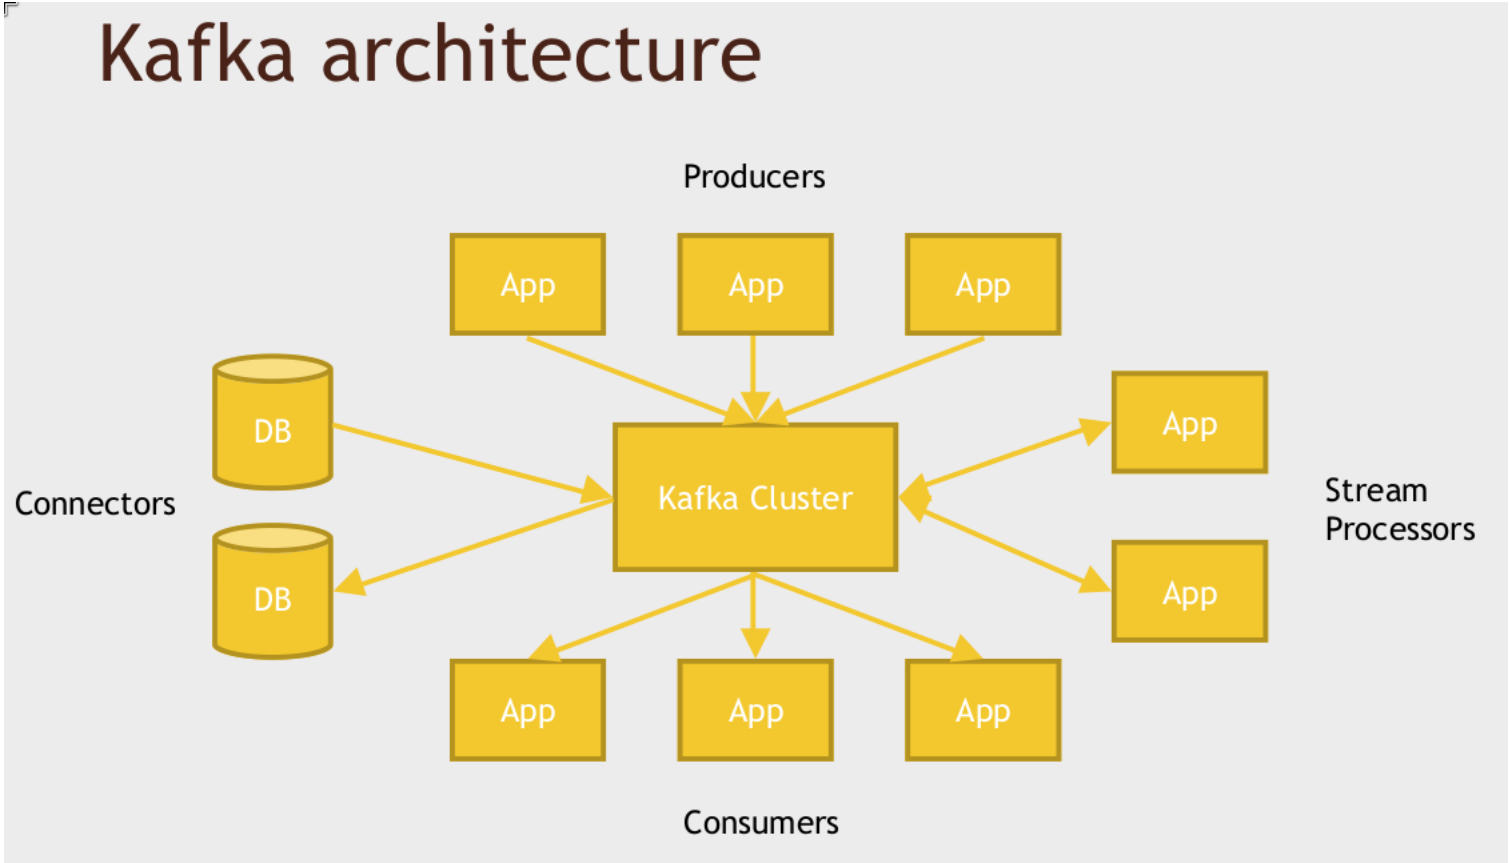
Kafka architecture
Producers
App
App
App
DB
DB
Connectors
Kafka Cluster
App
App
Stream
Processors
App
App
App
Consumers

Kafka

Como o Kafka escala:

- O próprio Kafka pode ser distribuído entre muitos processos em muitos servidores

- Distribuirá o armazenamento do fluxo dados bem

- Os consumidores também podem ser distribuídos

- Consumidores do mesmo grupo tem mensagens distribuídas entre eles

- Consumidores de diferentes grupos receberão sua própria cópia de cada mensagem

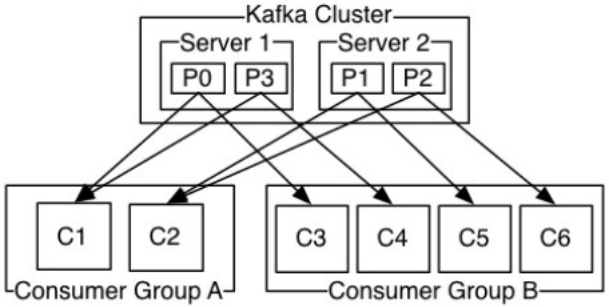

Obrigado!!!

Nos vemos amanhã!!!

Bom descanso!